




Kandinsky: запускаем и дообучаем модели генерации изображений и видео

Никита Киселев
Департамент ИИ-платформы и моделей

Диффузионные модели

Стохастические дифференциальные уравнения

Прямое СДУ (данные → шум)




Обратное СДУ (шум → данные)

нейронная сеть $\epsilon_{\theta}(\mathbf{x}_t, t)$

Современные архитектуры

Diffusion Transformer (Kandinsky 5)


- Диффузионный процесс происходит в латентном пространстве предобученного VAE
- Латент — это 4D-тензор $[T, H, W, C]$, который разбивается на патчи — токены для трансформера
- DiT состоит из последовательности блоков с Cross-Attention на текстовую инструкцию (промпт)



Современные архитектуры

Cross-DiT (Kandinsky 5)


1. Self-Attention
2. Cross-Attention (с промптом)
3. Feed Forward



Fully Sharded Data Parallel (FSDP)

Распределенное обучение на нескольких GPU

- Повышение эффективности обучения за счет использования нескольких GPU
- Увеличение размера батча при обучении
- Модели размером несколько миллиардов параметров не влезают на одну GPU



Fully Sharded Data Parallel (FSDP)

Распределенное обучение на нескольких GPU

Cross-DiT Block



All-Gather (перед forward / backward)




Loss.backward()



Освобождаем память от шардированных частей



Reduce-Scatter




Activation Checkpointing

Сохраняем не все промежуточные активации, а только между Cross-DiT блоками

Forward: внутри трансформерного блока не сохраняются внутренние тензоры; сохраняются только входы/выходы → можем использовать больше размер батча

Backward: при вычислении градиентов блок прогоняется еще раз на forward (с сохраненными входами), активации восстанавливаются на лету, затем считаются градиенты




Live Coding: дообучаем Kandinsky 5

Добавим в знания модели новую сущность — лабubu

Метод дообучения — LoRA

$$\Delta W = \begin{matrix} m & & n \\ & \text{A} & \text{B} \\ & r \ll m, n & \end{matrix}$$

Нам понадобятся



Картинки



+

Текстовые
описания

Милый пушистый персонаж лабubu коричневого цвета сидит на песчаном пляже под пальмами. Рядом лежит маленький радиоприемник, на фоне — голубое море и ясное небо с облаками. Атмосфера теплая и летняя.

Live Coding: формат данных для дообучения и генерации

Обучение




Задача: получить подробное текстовое описание

Алгоритм:

1. Пропускаем изображение через VLM
2. Нормализуем кэпшен:
 - Добавляем триггер слово
 - *Добавляем контекстную фразу

Инференс: текст → изображение/видео



Задача: повторить формат данных из обучения

Алгоритм:

1. Составляем подробный промпт
2. Добавляем триггер слово
3. *Добавляем контекстную фразу

Уникальное слово/токен, ассоциирующееся у модели с заданной сущностью