

Подпространство наибольшей кривизны в задаче стабилизации ландшафта функции потерь

Киселев Никита Сергеевич
Научный руководитель: к.ф.-м.н. Грабовой А. В.
Московский физико-технический институт

Конференция «Интеллектуализация обработки информации» (ИОИ-2026)

28 сентября 2026 г.

Законы масштабирования и достаточный размер выборки

Исследуется связь между архитектурой модели, локальной геометрией оптимизационной поверхности и объемом данных для устойчивого обучения.

Проблема

Эмпирические законы масштабирования хорошо воспроизводятся на практике, но не имеют общего теоретического объяснения; множество оптимальных параметров зависит от конечной обучающей выборки.

Требуется

Построить теоретическую схему, связывающую архитектуру модели, локальную кривизну поверхности функции потерь и достаточный размер обучающей выборки.

Метод решения

Анализ **стабилизации ландшафта функции потерь** при росте выборки: для нейронных сетей — через локальную геометрию и спектр матрицы Гессе, для линейных моделей — через апостериорные распределения параметров.

Разложение Гаусса—Ньютона матрицы Гессе

Функция потерь и матрица Гессе

$$\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^m, \quad \mathbf{x} \in \mathbb{R}^n, \quad \mathbf{y} \in \mathbb{R}^K$$

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell_i(\mathbf{w}), \quad \ell_i(\mathbf{w}) = \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i)$$

$$\mathbf{H}^{(m)}(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \mathbf{H}_i(\mathbf{w}) \in \mathbb{R}^{N \times N}$$

Обозначения на одном объекте

$$\mathbf{z} = f_{\mathbf{w}}(\mathbf{x}), \quad \mathbf{J} = \frac{\partial \mathbf{z}}{\partial \mathbf{w}} \in \mathbb{R}^{K \times N}, \quad \mathbf{A} = \nabla_{\mathbf{z}}^2 \ell \in \mathbb{R}^{K \times K}$$

Разложение Гаусса—Ньютона

$$\mathbf{H}(\mathbf{w}) = \mathbf{G}(\mathbf{w}) + \mathbf{R}(\mathbf{w})$$


$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w})$$

$$\mathbf{R}(\mathbf{w}) = \sum_{c=1}^K \frac{\partial \ell(\mathbf{z}, \mathbf{y})}{\partial z_c} \nabla_{\mathbf{w}}^2 z_c$$

Ключевая идея

При малых невязках $\mathbf{R}(\mathbf{w})$ мало и $\|\mathbf{G}\|_2 \approx \|\mathbf{H}\|_2$: кривизна анализируется через **компоненту $\mathbf{G}(\mathbf{w})$** .

Блочная факторизация гаусс—ньютоновской компоненты $\mathbf{G}(\mathbf{w})$



Лемма (Киселев, 2026)

Для нейронной сети $f_{\mathbf{w}}$ с архитектурой $\mathbf{z}^{(p)} = T_{\mathbf{w}^{(p)}}^{(p)}(\mathbf{x}^{(p)})$, $\mathbf{x}^{(p+1)} = \sigma^{(p)}(\mathbf{z}^{(p)})$, где операторы $T_{\mathbf{w}^{(p)}}^{(p)}$ линейны по входу, каждый блок $\mathbf{G}^{(p,q)}(\mathbf{w})$ выражается через параметрические якобианы слоев $\mathbf{P}^{(p)}(\mathbf{w}) = \partial \mathbf{z}^{(p)} / \partial \mathbf{w}^{(p)}$ и матрицы распространения возмущения $\mathbf{S}^{(p)}(\mathbf{w}) = \partial \mathbf{z} / \partial \mathbf{z}^{(p)}$ по формуле $\mathbf{G}^{(p,q)}(\mathbf{w}) = \mathbf{P}^{(p)\top} \mathbf{S}^{(p)\top} \mathbf{A}(\mathbf{w}) \mathbf{S}^{(q)} \mathbf{P}^{(q)}$.

Спектральные оценки и вычислительный эксперимент 1

Пусть $\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}$, $\|\mathbf{A}\|_2 \leq M_{\mathbf{A}}$, $\|\mathbf{D}^{(p)}\|_2 \leq M_{\sigma}$
($\mathbf{D}^{(p)}$ — производные активации).

Теорема (Киселев, 2024)

L -слойная **полносвязная** сеть,
 $\|\mathbf{W}^{(p)}\|_2 \leq M_{\mathbf{W}}$:

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} (M_{\mathbf{W}} M_{\sigma})^{2L-2}.$$

Теорема (Мешков, Киселев, 2024)


L -слойная **сверточная** сеть, $\|\mathcal{W}^{(p)}\|_1 \leq M_{\mathcal{W}}$,
 $K_{\max}$ — наибольшее число каналов:

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq LM_{\mathbf{x}}^2 M_{\mathbf{A}} K_{\max} (M_{\mathcal{W}} M_{\sigma})^{2L-2}.$$

Вывод

После первой эпохи $\|\mathbf{G}\|_2 / \|\mathbf{H}\|_2 \in [0,98; 1,03]$ у всех архитектур: кривизна определяется $\mathbf{G}$.

MNIST; сверточная сеть: $L \in \{2, 4, 8\}$ слоев
свертки 3×3 с $h \in \{64, 128, 256\}$ каналами
и линейный классификатор; нормы —
степенным методом.



Критерий сходимости поверхности функции потерь

Критерий p -сходимости ландшафта функции потерь при добавлении одного объекта в выборку $\mathfrak{D}_k$ с минимумом $\mathbf{w}_k^*$ функции $\mathcal{L}_k$:


$$\Delta_p(k+1) = \int |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|^p q(\mathbf{w}) d\mathbf{w},$$

где плотность q с основной массой вблизи $\mathbf{w}_k^*$ задает **пробное распределение**.

Утверждение (точное представление)

$$\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) = \frac{\ell_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})}{k+1} \implies \Delta_p(k+1) = \frac{\mathbb{E}_q |\ell_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|^p}{(k+1)^p}$$

Порядок k^{-p} универсален, содержание — в константе (кривизна, выбор q); в минимуме числитель в среднем равен разрыву обобщения.




Абсолютный одноточечный критерий сходимости

Абсолютный одноточечный критерий сходимости:

$$\Delta_1(k+1) = |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})|,$$

где $\mathbf{w} \in \mathcal{U}_R(\mathbf{w}_k^*)$ — точка из окрестности радиуса $R > 0$ минимума $\mathbf{w}_k^*$, т. е. $p = 1$ и $q(\tilde{\mathbf{w}}) = \delta(\tilde{\mathbf{w}} - \mathbf{w})$.



Теорема (Киселев, 2024)

Пусть в $\mathcal{U}_R(\mathbf{w}_k^*)$ справедлива квадратичная аппроксимация, $\|\mathbf{g}_{k+1}(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{g}}$ и для всех $i = 1, \dots, k+1$ верно $|\ell_i(\mathbf{w}_k^*)| \leq M_{\ell}$, $\|\mathbf{H}_i(\mathbf{w}_k^*)\|_2 \leq M_{\mathbf{H}}$, тогда


$$\Delta_1(k+1) \leq \frac{2M_{\ell} + M_{\mathbf{g}}R + M_{\mathbf{H}}R^2}{k+1} = \mathcal{O}(k^{-1}).$$

Среднеквадратичный критерий сходимости

Среднеквадратичный критерий сходимости:

$$\Delta_2(k+1) = \mathbb{E}_{q(\mathbf{w})} \left[(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],$$

т. е. $p = 2$ и $q(\mathbf{w}) = \mathcal{N}(\mathbf{w}_k^*, \sigma^2 \mathbf{I}_N)$; на практике критерий оценивается методом Монте—Карло по точкам $\mathbf{w}_s \sim q(\mathbf{w})$.



Теорема (Киселев, 2025)

В предположениях предыдущей теоремы

$$\Delta_2(k+1) \leq \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4(N^2 + 2N)M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}).$$


При $N \sim 10^8$ константа теряет практический смысл.

Критерий в подпространстве наибольшей кривизны

Обозначим $\mathbf{H}^{(k)}(\mathbf{w}_k^*)\mathbf{u}_i = \lambda_i^{(k)}\mathbf{u}_i$, $\lambda_1^{(k)} \geq \dots \geq \lambda_N^{(k)}$,
 $\mathbf{U}_D = [\mathbf{u}_1, \dots, \mathbf{u}_D]$, $\mathcal{S}_D = \text{Im}(\mathbf{U}_D)$. Критерий
с $\text{supp } q \subset \mathbf{w}_k^* + \mathcal{S}_D$:

$$\Delta_2^{(D)}(k+1) = \mathbb{E}_{q(\mathbf{w})} \left[(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],$$

где $\mathbf{w} = \mathbf{w}_k^* + \mathbf{U}_D \mathbf{z}$, $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_D)$.



Теорема (Киселев, 2026)

В предположениях предыдущих теорем

$$\Delta_2^{(D)}(k+1) \leq \frac{12M_\ell^2 + 3\sigma^2 M_{\mathbf{g}}^2 + 3\sigma^4 (D^2 + 2D) M_{\mathbf{H}}^2}{(k+1)^2} = \mathcal{O}(k^{-2}).$$

Масштабируемое вычисление критерия $\Delta_2^{(D)}$

Подпространство $\mathbf{U}_D$ строится итерационным методом на произведениях матрицы Гессе на вектор, без явного построения $\mathbf{H}^{(k)}$. В координатах $\mathbf{z} = \mathbf{U}_D^\top (\mathbf{w} - \mathbf{w}_k^*)$ критерий определяется тремя сжатыми объектами:

$$a_k = \mathcal{L}_{k+1}(\mathbf{w}_k^*) - \mathcal{L}_k(\mathbf{w}_k^*), \quad \mathbf{c}_k = \mathbf{U}_D^\top \nabla \mathcal{L}_{k+1}(\mathbf{w}_k^*), \quad \mathbf{B}_k = \mathbf{U}_D^\top (\mathbf{H}^{(k+1)} - \mathbf{H}^{(k)}) \mathbf{U}_D.$$

Алгоритм	Что оценивает	Стоимость оценки
Прямой метод Монте—Карло	истинный $\Delta_2^{(D)}$	$\mathcal{O}(S(ND + C_{\text{fwd}}))$
Квадратичный метод Монте—Карло	квадратичное приближение	$\mathcal{O}(SD^2)$
Замкнутая форма	квадратичное приближение	$\mathcal{O}(D^2)$

Замкнутая форма через моменты гауссовской квадратичной формы

$$\hat{\Delta}_2^{(D)}(k+1) = a_k^2 + a_k \sigma^2 \text{Tr } \mathbf{B}_k + \sigma^2 \|\mathbf{c}_k\|_2^2 + \frac{\sigma^4}{4} (2 \text{Tr } \mathbf{B}_k^2 + (\text{Tr } \mathbf{B}_k)^2)$$


Вычислительный эксперимент 2

MNIST; MLP с одним скрытым слоем ширины 64
($N \approx 5 \cdot 10^4$); k от 10^2 до 10^4 , 3 запуска.

Монте—Карло по 200 точкам, $\sigma = 0,5$;

$D \in \{5, 10, 20\}$.

Критерий	$\hat{\alpha}$ в $\Delta(k) \propto k^{-\alpha}$ (по запускам)	R^2
Δ_2	$1,94 \pm 0,07$	1,00
$\Delta_2^{(5)}$	$1,79 \pm 0,11$	0,96
$\Delta_2^{(10)}$	$1,83 \pm 0,07$	0,99
$\Delta_2^{(20)}$	$1,84 \pm 0,03$	0,99




Вывод

Δ_2 и $\Delta_2^{(D)}$ убывают степенным образом с показателем около 2, как в оценках; сужение на $D \leq 20$ направлений из $5 \cdot 10^4$ сохраняет скорость убывания.

Вычислительный эксперимент 3: трансформер nanochat d6

Декодерный трансформер глубины 6, $N \sim 10^8$,
контрольная точка обучения 3500; float32, только
произведения матрицы Гессе на вектор.

- 1) Точность квадратичной модели:
относительная ошибка приращения функции
потерь при изотропных возмущениях
масштаба σ (справа);
- 2) Время оценки $\Delta_2^{(D)}$ при $D = 45$, $\sigma = 10^{-3}$,
5 запусков: замкнутая форма в $\approx 1,8 \cdot 10^4$
раз быстрее прямого метода Монте—Карло
после построения подпространства.



Вывод

При $\sigma \leq 10^{-3}$ квадратичная модель точна (ошибка $\approx 10^{-3}$), и замкнутая форма
заменяет метод Монте—Карло: критерий вычислим для модели со 10^8 параметрами.

Достаточный размер выборки и законы масштабирования

Достаточный размер выборки

$$\Delta(m) \in \left\{ \Delta_1(m), \Delta_2(m), \Delta_2^{(D)}(m) \right\}$$

$$\forall m \geq m^* \quad \Delta(m) \leq \varepsilon$$

Архитектурно-зависимая кривизна

$$M_{\mathbf{G}}(\mathcal{A}) = \sup_{\mathbf{w} \in \mathcal{U}_R(\mathbf{w}^*)} \sup_i \|\mathbf{G}_i(\mathbf{w})\|_2$$

$$\|\mathbf{H}_i(\mathbf{w})\|_2 \leq M_{\mathbf{G}}(\mathcal{A}) + \delta_R$$

Декомпозиция среднего риска

$$\mathcal{L}(\mathbf{w}_m^*) = E + \Phi(N) + \mathcal{E}(m),$$

$E = \mathcal{L}(\mathbf{w}_\infty^*)$ — неустраняемая ошибка,

$\Phi(N) = \inf_{\mathcal{W}_N} \mathcal{L} - E$ — ошибка выразимости модели с N параметрами, $\mathcal{E}(m) = \mathcal{L}(\mathbf{w}_m^*) - \inf_{\mathcal{W}_N} \mathcal{L}$ — ошибка оценивания.

Предположение (локальный статистический режим)

$$\mathcal{E}(m) \leq C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R) m^{-\rho}, \quad \rho \in (0, 1].$$

Схема закона масштабирования

$$\mathcal{L}(\mathbf{w}_m^*) \leq E + \Phi(N) + \frac{C(M_{\mathbf{G}}(\mathcal{A}) + \delta_R)}{m^\rho}$$

Точно решаемый случай предположения о локальном режиме

Модель

$y = \mathbf{w}_\star^\top \mathbf{x} + \varepsilon$, $\mathbf{x} \sim \mathcal{N}(\mathbf{0}, \Sigma)$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, $\ell = \frac{1}{2}(y - \mathbf{w}^\top \mathbf{x})^2$, $\hat{\mathbf{w}}_m$ — МНК-оценка по $m > n + 1$ объектам, $\mathbf{x} \in \mathbb{R}^n$.

Утверждение

$$\mathbb{E} \mathcal{L}(\hat{\mathbf{w}}_m) - \mathcal{L}(\mathbf{w}_\star) = \frac{\sigma^2 n}{2(m - n - 1)} = \frac{\text{Tr}(\mathbf{H}^{-1} \mathbf{C})}{2m} \left(1 + \frac{n + 1}{m - n - 1} \right),$$

где $\mathbf{H} = \Sigma$ — матрица Гессе, $\mathbf{C} = \text{Cov} \nabla \ell(\mathbf{w}_\star) = \sigma^2 \Sigma$ — ковариация градиентов.

- 1) Предположение выполнено точно: $\rho = 1$, $\delta_R = 0$, $\Phi(N) = 0$;
- 2) Ландшафт точно квадратичен, поэтому замкнутая форма $\hat{\Delta}_2^{(D)}$ точна;
- 3) Константа определяется **отношением шума к кривизне** $\text{Tr}(\mathbf{H}^{-1} \mathbf{C})$, а не нормой $\|\mathbf{G}\|_2$.

Стабилизация правдоподобия линейной регрессии в точке ОМП

Вероятностная линейная регрессия

$$\mathbf{X}_m = [\mathbf{x}_1, \dots, \mathbf{x}_m]^\top \in \mathbb{R}^{m \times n}, \quad \mathbf{y}_m \in \mathbb{R}^m$$

$$L(\mathfrak{D}_m, \mathbf{w}) = p(\mathbf{y}_m | \mathbf{X}_m, \mathbf{w}) = \prod_{i=1}^m \mathcal{N}(y_i | \mathbf{w}^\top \mathbf{x}_i, \sigma^2)$$


$$\hat{\mathbf{w}}_k = \arg \max_{\mathbf{w} \in \mathbb{R}^n} L(\mathfrak{D}_k, \mathbf{w}), \quad \mathbb{E} \hat{\mathbf{w}}_k = \mathbf{m}_k, \quad \mathbb{D} \hat{\mathbf{w}}_k = \Sigma_k$$

M -достаточный размер: $\forall k \geq m^*$

$$M(k+1) = |\mathbb{E}_{\mathfrak{D}_{k+1}} L(\mathfrak{D}_m, \hat{\mathbf{w}}_{k+1}) - \mathbb{E}_{\mathfrak{D}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k)| \leq \varepsilon$$

Теорема (Киселев, 2024)

Пусть $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$ при $k \rightarrow \infty$, тогда определение M -достаточности корректно: $\forall \varepsilon > 0 \exists m^* \forall k \geq m^* M(k) \leq \varepsilon$.



D -достаточный размер:

$$\forall k \geq m^*$$


$$D(k) = \mathbb{D}_{\mathfrak{D}_k} L(\mathfrak{D}_m, \hat{\mathbf{w}}_k) \leq \varepsilon$$

Апостериорные распределения линейной регрессии на подвыборках

Апостериоры на схожих подвыборках $|\mathfrak{D}_k \triangle \mathfrak{D}_{k+1}| = 1$

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w} | \mathbf{m}_0, \Sigma_0), \quad p_k(\mathbf{w}) = p(\mathbf{w} | \mathfrak{D}_k) = \mathcal{N}(\mathbf{w} | \mathbf{m}_k, \Sigma_k)$$

$$\Sigma_k^{-1} = \Sigma_0^{-1} + \frac{1}{\sigma^2} \mathbf{X}_k^\top \mathbf{X}_k, \quad \mathbf{m}_k = \Sigma_k \left(\Sigma_0^{-1} \mathbf{m}_0 + \frac{1}{\sigma^2} \mathbf{X}_k^\top \mathbf{y}_k \right)$$



$$D_{\text{KL}}(p \| q) = \int p(\mathbf{w}) \log \frac{p(\mathbf{w})}{q(\mathbf{w})} d\mathbf{w}, \quad \text{s-score}(p, q) = \frac{\int p(\mathbf{w}) q(\mathbf{w}) d\mathbf{w}}{\max_{\mathbf{b}} \int p(\mathbf{w} - \mathbf{b}) q(\mathbf{w}) d\mathbf{w}}$$

KL -достаточный размер: $\forall k \geq m^*$

S -достаточный размер: $\forall k \geq m^*$

$$KL(k+1) = D_{\text{KL}}(p_k \| p_{k+1}) \leq \varepsilon$$

$$S(k+1) = \text{s-score}(p_k, p_{k+1}) \geq 1 - \varepsilon$$


Теорема (Киселев, 2024)

Пусть для всех $i = 1, \dots, k+1$ верно $\|\mathbf{x}_i\|_2 \leq M_{\mathbf{x}}$, $|y_i| \leq M_y$ и $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k) = \omega(\sqrt{k})$, тогда определения KL - и S -достаточности корректны, а для разбиения

$\mathfrak{D}_m = \mathfrak{D}_{m_1}^{\text{train}} \sqcup \mathfrak{D}_{m_2}^{\text{test}}$ верно $D_{\text{KL}}(p(\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k) \| p(\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_{k+1}, \mathbf{y}_{k+1})) \rightarrow 0$.

Вычислительный эксперимент 4

Синтетические регрессия и классификация, данные Liver Disorders (UCI). Для каждого порога ε вычисляется достаточный размер m^* по критериям D , M , KL , S (для классификации — D и M).



Вывод

Все критерии дают монотонную зависимость $m^*(\varepsilon)$: порог напрямую переводится в требуемый размер выборки. Значения ε разных критериев несопоставимы, так как они измеряют разные величины.

Выносятся на защиту

- 1) Теоремы о верхних оценках спектральной нормы гаусс—ньютоновской компоненты матрицы Гессе для полносвязных и сверточных архитектур нейронных сетей.
- 2) Критерии стабилизации ландшафта функции потерь в нейронных сетях, построенные для одной точки, для распределения точек в полном пространстве параметров и для подпространства главных собственных направлений матрицы Гессе, с оценками, в которых константа явно зависит от кривизны, а для подпространства N заменяется на $D \ll N$.
- 3) Масштабируемые алгоритмы вычисления подпространственного критерия на произведениях матрицы Гессе на вектор.
- 4) Теоретическая схема законов масштабирования параметрических моделей машинного обучения, связывающая архитектуру модели, локальную кривизну оптимизационной поверхности и объем обучающей выборки, при предположении о локальном статистическом режиме, выполняющемся точно для линейной модели.
- 5) Критерии достаточного размера выборки для параметрических моделей, основанные на стабилизации ландшафта функции потерь, и для вероятностных линейных моделей, основанные на стабилизации распределения оптимальных параметров.

Список работ автора по теме диссертации

Публикации в рецензируемых научных журналах (BAK, Web of Science, Scopus)

- 1) *Enikeev A., Kiselev N., Grabovoy A.* Adaptive Selection of the Gaussian Sampling Scale for Monte Carlo Estimation of Loss-Landscape Convergence // *Proceedings of the ISP RAS*, 2026.
- 2) *Kiselev N., Meshkov V., Grabovoy A.* Robust Convergence of Loss Landscapes through Distributional Averaging // *Proceedings of the ISP RAS*, 2025.
- 3) *Kiselev N., Grabovoy A.* Sample Size Determination: Posterior Distributions Proximity // *Computational Management Science*, 2025.
- 4) *Kiselev N., Grabovoy A.* Sample Size Determination: Likelihood Bootstrapping // *Computational Mathematics and Mathematical Physics*, 2025.
- 5) *Meshkov V., Kiselev N., Grabovoy A.* ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks // *Ivannikov ISPRAS Open Conference*, 2024.
- 6) *Kiselev N., Grabovoy A.* Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // *Doklady Mathematics*, 2024.

Выступления с докладом

- 1) Среднеквадратичный критерий сходимости ландшафта функции потерь на основе перехода к подпространству главных собственных векторов матрицы Гессе // *68-я Всероссийская научная конференция МФТИ*, 2026.
- 2) Устойчивая сходимость поверхности функции потерь через усреднение по распределению // *Открытая конференция ИСП РАН*, 2025.
- 3) Достаточный размер выборки и его связь со сходимостью поверхности функции потерь // *22-я Всероссийская конференция с международным участием «Математические методы распознавания образов»*, 2025.
- 4) Сходимость поверхности функции потерь как признак достаточного размера выборки // *67-я Всероссийская научная конференция МФТИ*, 2025.
- 5) Определение достаточного размера выборки по апостериорному распределению параметров модели // *66-я Всероссийская научная конференция МФТИ*, 2024.