

Адаптивный выбор параметров распределения сэмплирования для Monte Carlo оценки сходимости оптимизационной поверхности

Еникеев А.Н., Киселёв Н.С., Грабовой А.В.

Кафедра интеллектуальных систем
Московский физико-технический институт

29.05.2026

Цель исследования

Понимание локального поведения функции потерь возле минимума важно для анализа ландшафта функции потерь параметрических моделей и для исследования поведения геометрии оптимизационной поверхности при росте размера обучающей выборки.

Задача: Предложить метод выбора масштаба гауссовского сэмплирования в окрестности минимума, при котором квадратичная аппроксимация Тейлора будет выполняться с заданной точностью.


Предлагаемое решение: Выбирать параметр дисперсии сэмплирования на основе спектра матрицы Гессе и оценки изменения локальной кривизны в окрестности минимума:

$$\sigma^* = \frac{R_\psi}{\sqrt{\chi_{1-\varepsilon}^2(d)}}, \quad R_\psi = \min \left\{ r, \frac{3\psi \lambda_{\min}(\mathbf{H}_d)}{L_{\mathbf{H}}} \right\}.$$

Задача

Ландшафт $\mathcal{L}(\mathbf{w})$ исследуется с помощью гауссовского сэмплирования с центром в минимуме.

Задача состоит в том, чтобы найти параметры сэмплирования $\mathcal{N}(\mathbf{w}^*, \Sigma)$ так, чтобы точки сэмплирования попадали в $\mathcal{B}_R(\mathbf{w}^*)$, где R – характерный радиус шара, в котором **квадратичная аппроксимация Тейлора** выполнена с заданной точностью.



Постановка задачи

Пусть $\mathcal{L}_k(\mathbf{w}) : \mathbb{R}^N \rightarrow \mathbb{R}$ – функция потерь модели $f_{\mathbf{w}} : \mathbb{X} \rightarrow \mathbb{Y}$ на выборке $\mathcal{D}_k = \{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^k$ из k i.i.d. сэмплов из распределения $p(\mathbf{x}, \mathbf{y})$. Обозначим через $\mathbf{w}_k^*$ минимум функции потерь на этой выборке:

$$\mathbf{w}_k^* \in \arg \min_{\mathbf{w} \in \mathbb{R}^N} \mathcal{L}_k(\mathbf{w})$$

Предположим, что $\mathcal{L}_k$ дважды непрерывно дифференцируема в окрестности $\mathbf{w}_k^*$. Для малого возмущения $\mathbf{h}$ имеем

$$\mathcal{L}_k(\mathbf{w}_k^* + \mathbf{h}) = \mathcal{L}_k(\mathbf{w}_k^*) + \nabla \mathcal{L}_k(\mathbf{w}_k^*)^\top \mathbf{h} + \frac{1}{2} \mathbf{h}^\top \mathbf{H}_k \mathbf{h} + \rho_k(\mathbf{h}).$$

Так как $\mathbf{w}_k^*$ — локальный минимум, то $\nabla \mathcal{L}_k(\mathbf{w}_k^*) = 0$, поэтому локальное поведение задаётся выражением

$$\mathcal{L}_k(\mathbf{w}_k^* + \mathbf{h}) = \mathcal{L}_k(\mathbf{w}_k^*) + \frac{1}{2} \mathbf{h}^\top \mathbf{H}_k \mathbf{h} + \rho_k(\mathbf{h}).$$

Постановка задачи

Требование к области сэмплирования: для заданной точности $\psi > 0$ остаточный член в аппроксимации должен быть мал относительно квадратичного члена:

$$|\rho_k(\mathbf{h})| \leq \psi \cdot \frac{1}{2} \mathbf{h}^\top \mathbf{H}_k \mathbf{h}$$

Проблема: Пространство параметров анизотропно и имеет большую размерность, поэтому основное изменение функции потерь сосредоточено в низкоразмерном подпространстве, соответствующем ведущим собственным векторам матрицы Гессе. Пусть $\lambda_1^{(k)} \geq \lambda_2^{(k)} \geq \dots \geq \lambda_N^{(k)}$ — собственные значения $\mathbf{H}_k$. Обозначим за

$$\mathbf{U}_{k,d} = [\mathbf{u}_1^{(k)}, \dots, \mathbf{u}_d^{(k)}] \in \mathbb{R}^{N \times d}$$

матрицу, составленную из d главных собственных векторов $\mathbf{H}_k$.

Подпространство наибольшей кривизны:

$$\mathcal{S}_{k,d} = \text{span}\{\mathbf{u}_1^{(k)}, \dots, \mathbf{u}_d^{(k)}\}.$$

В этих направлениях функция потерь меняется наиболее сильно, поэтому для локального анализа они наиболее информативны.

Сэмплирование в подпространстве наибольшей кривизны

Вместо всего пространства $\mathbb{R}^N$ будем рассматривать сэмплирование в $S_{k,d}$:

$$\mathbf{w} = \mathbf{w}_k^* + \mathbf{U}_{k,d}\mathbf{z}, \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_d).$$

где $\sigma > 0$ отвечает за дисперсию сэмплирования.

Ключевая задача заключается в корректном выборе параметра σ : если значение будет слишком маленьким, то сэмплирование не даст достаточно информации о ландшафте, а если взять σ слишком большим, то нарушится корректность аппроксимации Тейлора.

Пусть $R_{\psi,k} > 0$ — характерный радиус шара, в котором для любого возмущения $\mathbf{h} \in \mathcal{S}_{k,d}$, удовлетворяющего условию, $\|\mathbf{h}\|_2 \leq R_{\psi,k}$ выполнено

$$\rho_k(\mathbf{h}) \leq \psi \frac{1}{2} \mathbf{h}^\top \mathbf{H}_k \mathbf{h}$$

Цель работы: найти параметр σ^* , для которого при данном сэмплировании выполнено:

$$\sigma^* = \sup (\sigma > 0 : \mathbb{P}(\|\mathbf{w}_k - \mathbf{w}_k^*\| < R_\psi) > 1 - \varepsilon)$$

где $1 - \varepsilon$ — вероятность, с которой мы хотим попадать в шар характерного радиуса.

Предположения

Для краткости опустим индекс k :

$$\mathcal{L} = \mathcal{L}_k, \quad \mathbf{w}^* = \mathbf{w}_k^*, \quad \mathbf{H} = \mathbf{H}_k, \quad \mathbf{U}_d = \mathbf{U}_{k,d}.$$

Рассматриваем только возмущения вида $\mathbf{h} = \mathbf{U}_d \mathbf{z}$, где $\mathbf{z} \in \mathbb{R}^d$. Столбцы $\mathbf{U}_d$ ортонормированы, поэтому $\|\mathbf{h}\|_2 = \|\mathbf{z}\|_2$.

Предположение 1: Существует радиус $r > 0$, такой что в подпространстве наибольшей кривизны матрица Гессе липшицева в шаре $\mathcal{B}_r(\mathbf{w}^*)$:

$$\|\nabla^2 \mathcal{L}(\mathbf{u}) - \nabla^2 \mathcal{L}(\mathbf{v})\|_2 \leq L_{\mathbf{H}} \|\mathbf{u} - \mathbf{v}\|_2, \quad \forall \mathbf{u}, \mathbf{v} \in \mathcal{B}_r(\mathbf{w}^*).$$

Матрица Гессе в подпространстве наибольшей кривизны:

$$\mathbf{H}_d = \mathbf{U}^T \mathbf{H} \mathbf{U}$$

Предположение 2: Собственные значения матрицы Гессе в $\mathcal{S}_d$ положительны:

$$\lambda_{\min}(\mathbf{H}_d) > 0$$

Условие предположения 2 достигается выбором размерности d .

Выражение для характерного радиуса

По формуле Тейлора с остаточным членом в интегральной форме:

$$\rho(\mathbf{h}) = \int_0^1 (1-t) \mathbf{h}^\top [\nabla^2 \mathcal{L}(\mathbf{w}^* + t\mathbf{h}) - \nabla^2 \mathcal{L}(\mathbf{w}^*)] \mathbf{h} dt.$$

Из липшицевости матрицы Гессе при $\|\mathbf{h}\|_2 \leq r$ получаем:

$$|\rho(\mathbf{h})| \leq \frac{L_{\mathbf{H}}}{6} \|\mathbf{h}\|_2^3.$$

Для $\mathbf{h} = \mathbf{U}_d \mathbf{z}$ квадратичный член снизу оценивается через минимальное собственное значение:

$$\mathbf{h}^\top \mathbf{H} \mathbf{h} = \mathbf{z}^\top \mathbf{H}_d \mathbf{z} \geq \lambda_{\min}(\mathbf{H}_d) \|\mathbf{z}\|_2^2.$$

Поэтому достаточно требовать

$$\|\mathbf{h}\|_2 \leq R_\psi = \min \left\{ r, \frac{3\psi \lambda_{\min}(\mathbf{H}_d)}{L_{\mathbf{H}}} \right\}.$$

Максимальное значение параметра σ^*

При сэмплировании

$$\mathbf{w} = \mathbf{w}^* + \mathbf{U}_d \mathbf{z}, \quad \mathbf{z} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_d),$$

из ортонормированности $\mathbf{U}_d$ имеем

$$\|\mathbf{w} - \mathbf{w}^*\|_2^2 = \|\mathbf{z}\|_2^2, \quad \frac{\|\mathbf{z}\|_2^2}{\sigma^2} \sim \chi^2(d).$$

Нужно выбрать максимальный масштаб, при котором гауссовский вектор остаётся внутри радиуса R_ψ с вероятностью не меньше $1 - \varepsilon$:

$$\mathbb{P}(\|\mathbf{w} - \mathbf{w}^*\|_2 \leq R_\psi) \geq 1 - \varepsilon.$$

Отсюда получаем

$$\sigma^* = \frac{R_\psi}{\sqrt{\chi_{1-\varepsilon}^2(d)}} = \frac{1}{\sqrt{\chi_{1-\varepsilon}^2(d)}} \min \left\{ r, \frac{3\psi \lambda_{\min}(\mathbf{H}_d)}{L_{\mathbf{H}}} \right\}$$

Практическая оценка $L_{\mathbf{H}}$

Полученная формула зависит от величин, которые нельзя напрямую вычислить в больших моделях, в частности от константы Липшица матрицы Гессе в $\mathcal{S}_d$.

Для $\boldsymbol{\xi} \in \mathbb{R}^d$ определим: $\mathbf{H}_d(\boldsymbol{\xi}) = \mathbf{U}_d^\top \nabla^2 \mathcal{L}(\mathbf{w}^* + \mathbf{U}_d \boldsymbol{\xi}) \mathbf{U}_d$; $\mathbf{H}_d(0) = \mathbf{H}_d$.

Выбираются случайные единичные направления $\mathbf{v}_1, \dots, \mathbf{v}_M \in \mathbb{R}^d$ и малый шаг $t > 0$:

$$\hat{L}_{\mathbf{H}}(\mathbf{v}_m; t) = \frac{\|\mathbf{H}_d(t\mathbf{v}_m) - \mathbf{H}_d(0)\|_2}{t}.$$

Итоговая оценка выбирается как максимум по направлениям:

$$\hat{L}_{\mathbf{H}} = \max_{1 \leq m \leq M} \hat{L}_{\mathbf{H}}(\mathbf{v}_m; t).$$

Тогда практическая оценка для σ^* будет следующей:

$$\hat{\sigma}^* = \frac{1}{\sqrt{\chi_{1-\varepsilon}^2(d)}} \min \left\{ r, \frac{3\psi \lambda_{\min}(\mathbf{H}_d)}{\hat{L}_{\mathbf{H}}} \right\}$$

Вычислительный эксперимент

Вычислительный эксперимент проводился для модели ResNet-18 на датасете CIFAR-10.

Основные шаги:

1. обучить ResNet-18 и взять найденные веса как опорный минимум $\mathbf{w}^*$;
2. с помощью Hessian-vector product и Power Iteration найти главные собственные собственные векторы и собственные значения матрицы Гессе;
3. для каждого значения d построить $\mathbf{U}_d = [\mathbf{u}_1, \dots, \mathbf{u}_d]$ и $\mathbf{H}_d = \mathbf{U}_d^\top \mathbf{H} \mathbf{U}_d$;
4. оценить $\hat{L}_{\mathbf{H}}$ по случайным направлениям внутри $\mathcal{S}_d$;
5. вычислить выражение для параметра $\hat{\sigma}^*$

$$\hat{\sigma}^* = \frac{1}{\sqrt{\chi_{1-\varepsilon}^2(d)}} \min \left\{ r, \frac{3\psi \lambda_{\min}(\mathbf{H}_d)}{\hat{L}_{\mathbf{H}}} \right\};$$


6. проверить качество квадратичной аппроксимации при $\sigma = \alpha \hat{\sigma}^*$.

Эксперимент 1: зависимость от размерности d

На графике показана нормированная величина $\hat{\sigma}^*(d)/\hat{\sigma}^*(10)$.

По графику видно, что значение параметра σ^* быстро уменьшается с ростом размерности d .



Это объясняется тем, что с ростом d растёт квантиль $\chi^2_{1-\varepsilon}(d)$, а при добавлении новых направлений величина $\lambda_{\min}(\mathbf{H}_d)$ также уменьшается. Это значит, что в будущих исследованиях важно корректно выбирать значение параметра d .



Для модели из эксперимента малые значения d порядка 10 дают компромисс между информативностью сэмплирования и устойчивостью квадратичной аппроксимации.

Эксперимент 2: корректность квадратичной аппроксимации

Для проверки корректности квадратичной аппроксимации для $\sigma = \alpha \hat{\sigma}^*$ сравнивались реальные значения функции потерь с её квадратичной аппроксимацией.



При $\alpha \approx 1$, то есть при $\sigma \approx \hat{\sigma}^*$, отношение остаётся близким к единице, значит сэмплы находятся внутри локального квадратичного режима. При увеличении α отклонение быстро растёт, что подтверждает теоретические результаты.

1. В работе предложено **адаптивное правило** для выбора масштаба гауссовского сэмплирования вблизи минимума функции потерь. Метод основан на оценке характерного радиуса корректности аппроксимации Тейлора и приводит к явному выражению для максимально допустимого масштаба сэмплирования при заданной доверительной вероятности.
2. Эксперименты на **ResNet-18**, обученной на **CIFAR-10**, подтверждают предложенный подход. В частности, результаты показывают, что выбранный масштаб согласуется с областью, в которой квадратичная аппроксимация Тейлора остаётся точной, тогда как более крупные возмущения быстро выводят за пределы этого режима.
3. Показан характер зависимости полученного выражения для σ^* от размерности d , что позволит эффективно использовать метод в будущих исследованиях.