

Анализ сходимости поверхности функции потерь сверточных нейросетевых моделей на основе Гессиана

Владислав Мешков, Никита Киселев, Андрей Грабовой

Московский Физико-Технический Институт

Проблема

Число данных для обучения нейросетей, а также число параметров растет и необходимо изучать связь между сложностью моделей и необходимым числом объектов в обучающей выборке.

Цель

Изучить сходимость поверхности функции потерь в пространстве параметров при изменении размера выборки для сетей, представленных в виде произведения зависимых от входа матриц.

Решение

1. Рассмотреть взаимосвязь гессиана со сходимостью функции потерь.
2. Посчитать норму гессиана для сетей, представленного в виде произведения матриц и применить данные результат к сверточным сетям.

Постановка задачи

Пусть f_{θ} - нейросеть, y_k -one-hot метки для классификации, x_k -входы, $\mathcal{L}_k$ - функция потерь на k 'м объекте.

Изменение значения при добавлении одного объекта

$$\mathcal{L}_{k+1}(\theta) - \mathcal{L}_k(\theta) = \frac{1}{k+1} (\ell(f_{\theta}(x_{k+1}), y_{k+1}) - \mathcal{L}_k(\theta))$$

Предположение 1


Пусть θ^* является точкой локального минимума обеих функций $\mathcal{L}_k(\theta)$ и $\mathcal{L}_{k+1}(\theta)$:

$$\nabla \mathcal{L}_k(\theta^*) = \nabla \mathcal{L}_{k+1}(\theta^*) = 0.$$

Аппроксимация второго порядка

$$\mathbf{H}^{(k)} = \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\theta) = \frac{1}{k} \sum_{i=1}^k \nabla_{\theta}^2 \ell(f_{\theta}(x_i), y_i)$$

$$\mathcal{L}_k(\theta) \approx \mathcal{L}_k(\theta^*) + \frac{1}{2}(\theta - \theta^*)^T \mathbf{H}^{(k)}(\theta^*)(\theta - \theta^*)$$



Связь изменения функции потерь с Гессианом

Абсолютное изменение функции потерь

$$|\mathcal{L}_{k+1}(\boldsymbol{\theta}) - \mathcal{L}_k(\boldsymbol{\theta})| \leq \frac{1}{k+1} \left| \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \frac{1}{k} \sum_{i=1}^k \ell(f_{\boldsymbol{\theta}^*}(\mathbf{x}_i), \mathbf{y}_i) \right| + \\ + \frac{1}{k+1} \|\boldsymbol{\theta} - \boldsymbol{\theta}^*\|_2^2 \left\| \mathbf{H}_{k+1}(\boldsymbol{\theta}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\boldsymbol{\theta}^*) \right\|_2$$

Декомпозиция Гессиана

$$\mathbf{H}_i(\boldsymbol{\theta}) = \underbrace{\nabla_{\boldsymbol{\theta} \mathbf{z}_i} \frac{\partial^2 \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial \mathbf{z}_i^2} \nabla_{\boldsymbol{\theta} \mathbf{z}_i^\top}}_{\mathbf{H}_O} + \underbrace{\sum_{k=1}^K \frac{\partial \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial z_{ik}} \nabla_{\boldsymbol{\theta} z_{ik}}^2}_{\mathbf{H}_F}$$

Аппроксимация Гессиана

- Аппроксимируем Гессиан, пренебрегая $\mathbf{H}_F$. В задаче K -классовой классификации $\|\mathbf{H}_O\| \ll \|\mathbf{H}_F\|$
- Тогда можно оценить $\|\mathbf{H}\| \approx \|\mathbf{H}_O\|$.

Нейросети представимые в виде произведения матриц

Рассмотрим нейросети специального вида, а именно представимые в виде произведения матриц, возможно зависящих от входа.

Пусть нейросеть $f_{\theta}(\mathbf{x}) := \mathbf{T}^{(L+1)} \mathbf{\Lambda}^{(L)} \dots \mathbf{\Lambda}^{(1)} \mathbf{T}^{(1)} \mathbf{x}$, где

- $\mathbf{x}$ - вход
- $\mathbf{T}^{(l)}$ - матрица линейного слоя l
- $\mathbf{\Lambda}$ -матрица *ReLU*-активации l' 'го слоя, зависящая от входа $\mathbf{x}$

Структура $\mathbf{H}_O$ компоненты Гессиана

Рассмотрим матрицы:

- $\mathbf{F}$ - матрица сложной структуры, зависящая только от всех $\mathbf{T}^{(i)}, \mathbf{\Lambda}^{(i)}$ и от $\mathbf{x}$
- $\mathbf{A} = \text{diag}(\mathbf{p}) - \mathbf{p}^2$, где $\mathbf{p}$ -вектор вероятностей классов для $\mathbf{x}$
- $\mathbf{Q}^{(p)} := \frac{\partial T^{(p)}}{\partial \mathbf{W}^{(p)}}$, где $\mathbf{W}^{(p)}$ -параметры p' го слоя.

Лемма 1

$$\mathbf{H}_O(\boldsymbol{\theta}) = \mathbf{Q}^\top \mathbf{F} \mathbf{A} \mathbf{F}^\top \mathbf{Q}.$$

Данная Лемма позволяет представить норму $\mathbf{H}_O$ компоненты Гессиана на произведение норм более простых блоков.

Лемма 2

Пусть $\|\mathbf{Q}^{(p)}\|_2 \leq q$, $\|\mathbf{T}^{(p)}\|^2 \leq w_{\mathbf{T}}^2 \quad \forall p$, тогда
 $\|\mathbf{H}_O\| \leq \sqrt{2}q^2 \|\mathbf{x}\|^2 (L+1)w_{\mathbf{T}}^{2L}$.

Оценка нормы $\mathbf{H}_O$ как функция весов является степенной, а как функция числа слоев - показательной.

Лемма 2 является основой для оценки нормы гессиана в дальнейшем.

Из Леммы, для того, чтобы оценить Гессиан, достаточно оценить $\|\mathbf{Q}^{(p)}\|$ и $\|\mathbf{T}^{(p)}\|$ одновременно для всех слоев, что и будет сделано в будущих результатах.

Свертки как линейная операция

Действие свертки на $\mathbf{x} \in \mathbb{R}^{C \times d}$, представим линейным оператором, действующим на $\mathbf{x} \in \mathbb{R}^{C \times d}$, причем с сохранением обозначений : $\mathbf{T}^{(l)} * \mathbf{x} \rightarrow \mathbf{T}^{(l)} \mathbf{x}$

$$\begin{pmatrix} t_1 & t_2 & t_3 \end{pmatrix} * \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{pmatrix} \rightarrow \begin{pmatrix} t_1 & t_2 & t_3 & 0 & 0 \\ 0 & t_1 & t_2 & t_3 & 0 \\ 0 & 0 & t_1 & t_2 & t_3 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{pmatrix}$$

Теорема 1

Пусть $C_l \leq C$, $k_i \leq k$, $d_i \leq d$, $|W_{i,j,k}^{(p)}|^2 \leq w^2$, где C_l, k_l, d_l - число каналов, размер ядра и пространственный размер соответственно, тогда

$$\|\mathbf{H}_O\| \leq \sqrt{2} \|x\|^2 d^2 (L+1) (C^2 w^2 k d)^L$$

Из Теоремы видно, что оценка нормы является степенной функцией от числа каналов, весов, размера ядра и размера последовательности

Теорема 2

Пусть $|\mathbf{W}_{i,j,k}^{(p)}|^2 \leq w^2$, где $\mathbf{W}^{(p)}$ - веса p -го слоя свертки

$C_l, k_l, (m_l, n_l)$ - число каналов, размер ядра, пространственные размеры карты признаков соответственно на l -м слое нейросети. Пусть

$C_l \leq C, k_l \leq k, m_l \leq m, n_l \leq n$, тогда

$$\|\mathbf{H}_O\| \leq \sqrt{2} \|x\|^2 C^2 k^2 m n (L+1) (C^2 k^2 w^2 m n)^L.$$

Результат полученный в **Теореме 1** отличается от данного лучшей оценкой

$\|\mathbf{Q}^{(p)}\|$, это связано с различием в структуре Теплицевых матриц 1D и 2D сверток.

Лемма 3

Пусть на месте l -й нелинейности находится max/avg пулинг, причем пусть ядро: $k_P \times k_P$, $\text{stride} = k_P$, $\text{padding} = 0$, при этом верны все ограничения предыдущей теоремы, тогда:

$$\|\mathbf{H}_O\| \leq \sqrt{2} \|x\|^2 q^2 \frac{1}{k_P^{2(L-l+2)}} (L+1)(C^2 k^2 w^2 mn)^L$$

Лемма 4

Пусть после сверточных слоев находится полносвязная голова размера P :

$$f_{\theta}(\mathbf{x}) = \mathbf{T}^{(L+P+1)} \mathbf{\Lambda}^{(L+P)} \dots \mathbf{\Lambda}^{(L+1)} \mathbf{T}^{(L+1)} \mathbf{\Lambda}^{(L)} \dots \mathbf{\Lambda}^{(1)} \mathbf{T}^{(1)} \mathbf{x},$$



где $\mathbf{T}^{(L+1+i)}$ - Линейный слой с параметрами h_i, h_{i+1} , $\mathbf{T}^{(r)}$ -2D-свертки. Пусть имеют место оценки: $\|\mathbf{T}_{ij}^{(L+1+i)}\| \leq \tilde{w}$ и $h_p \leq h$. Тогда в условиях Теоремы имеем

$$\|\mathbf{H}_O\| \leq \sqrt{2} \|\mathbf{x}\|^2 C^2 k^2 mn (h^2 \tilde{w}^2)^P (k^2 C^2 w^2 mn)^L \times \left(L+1 + P \frac{h^2 \tilde{w}^2}{k^2 C^2 w^2 mn} \right). \quad 10/15$$

Постановка эксперимента



- **Задача:** классификация изображений.
- **Выборка:** MNIST, FashionMNIST, CIFAR10.
- **Архитектура:** L-слойная сверточная нейросеть с ReLU активациями.
- **Проверяемые гипотезы:** Абсолютная разница функции потерь растет в зависимости от
 1. числа сверточных слоев,
 2. размера ядра,
 3. числа фильтров.
- **Постановка эксперимента**
 1. Обучаем модель на полном наборе данных и получаем близкое к оптимальному $\hat{\theta}$,
 2. Находим для всех k : $\left| \mathcal{L}_{k+1}(\hat{\theta}) - \mathcal{L}_k(\hat{\theta}) \right|$ для всех $k = 1, \dots, m$,
 3. Предыдущий пункт повторяем меняя порядок элементов в выборке.

Число слоев





Графики демонстрируют шумное поведение, но видна тенденция: при увеличении размера выборки абсолютная разница функции потерь также увеличивается.

Размер ядра



При увеличении размера ядра, абсолютная разница функции потерь также растёт.

Число фильтров



Графики, как видно, демонстрируют обратный результат: при большем числе каналов разница явно меньше. Предположительно, результат таков, так как сети при большем числе фильтров лучше обучились и компонента с Гессианом влияла значительно меньше.

Основные результаты

1. Предложен способ оценки нормы гессиана для сетей, представленных в виде произведения матриц.
2. Данный результат применен для 2D/1D сверток, а также для пулингов и fc-головы.
3. Предложен способ оценки абсолютной разницы функции потерь для сверточных сетей, основываясь на гессиане.

Будущее работы

1. Улучшить теоретические оценки, пользуясь разреженностью матриц $\Lambda^{(i)}$.
2. Применить данные оценки к другим видам нейронных сетей.
3. Проанализировать другие способы оценки изменения ландшафта функции потерь.