

Устойчивая сходимость поверхности функции потерь через усреднение по распределению

Киселев Н. С., Мешков В. С., Грабовой А. В.

Кафедра интеллектуальных систем
Московский физико-технический институт
(национальный исследовательский университет)

10 декабря 2025 г.

Достаточный размер обучающей выборки и его связь со сходимостью поверхности функции потерь

Проблема

Количество данных для обучения модели неразрывно связано с ее сложностью. При этом всегда есть желание сократить число объектов для обучения.

Цель

Разработать методы определения необходимого числа данных для обучения модели с заранее определенным качеством. Связать количество данных со сложностью модели.

Источники для решения

- 1) Статистические критерии. ✗
- 2) Распределение параметров модели после обучения. ✓
- 3) Изменение функции потерь с ростом числа объектов. ✓

Задача определения достаточного размера выборки

Выборка

$$\mathfrak{D}_m = \{(\mathbf{x}_i, \mathbf{y}_i)\}, i \in \mathbb{I} = \{1, \dots, m\}$$

- 1) $\mathbf{x} \in \mathbb{X}$ — признаковое описание объекта;
- 2) $\mathbf{y} \in \mathbb{Y}$ — значение целевой переменной.

Вероятностная модель

$$p(\mathbf{y}, \mathbf{w}|\mathbf{x}) = p(\mathbf{y}|\mathbf{x}, \mathbf{w})p(\mathbf{w}) : \mathbb{Y} \times \mathbb{W} \times \mathbb{X} \rightarrow \mathbb{R}^+$$

- 1) $p(\mathbf{y}|\mathbf{x}, \mathbf{w})$ — правдоподобие;
- 2) $p(\mathbf{w})$ — априорное распределение.


Определение

Размер выборки m^* называется **достаточным** согласно критерию T , если T выполняется для всех $k \geq m^*$.


Требуется

- 1) Предложить критерий T определения достаточного размера выборки m^* ;
- 2) Построить метод, реализующий критерий T на практике.

Сходимость поверхности функции потерь¹²



(a) Loss function landscape



(b) Losses difference

¹Kiselev, N., & Grabovoy, A. (2024). Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes. Doklady Mathematics.

²Meshkov, V., Kiselev, N., and Grabovoy, A. (2024). ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks. Ivannikov Ispras Open Conference (ISPRAS).

Обозначения

Выборка

$$\mathfrak{D} = \{(\mathbf{x}_i, \mathbf{y}_i)\}, \quad i = 1, \dots, m, \quad \mathbf{x} \in \mathcal{X}, \mathbf{y} \in \mathcal{Y}$$

Модель

Условное распределение $p(\mathbf{y}|\mathbf{x})$ аппроксимируется нейросетью $f_{\mathbf{w}} : \mathcal{X} \rightarrow \mathcal{Y}$ с параметрами $\mathbf{w} \in \mathbb{R}^N$.

Функция потерь

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i) \approx \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim p(\mathbf{x}, \mathbf{y})} [\ell(f_{\mathbf{w}}(\mathbf{x}), \mathbf{y})]$$

Изменение значения при добавлении одного объекта

$$\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) = \frac{1}{k+1} (\ell(f_{\mathbf{w}}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \mathcal{L}_k(\mathbf{w}))$$

Аппроксимация второго порядка

Предположение 1

Пусть $\mathbf{w}^*$ является точкой минимума обеих функций $\mathcal{L}_k(\mathbf{w})$ и $\mathcal{L}_{k+1}(\mathbf{w})$, то есть $\nabla \mathcal{L}_k(\mathbf{w}^*) = \nabla \mathcal{L}_{k+1}(\mathbf{w}^*) = \mathbf{0}$.

Аппроксимация второго порядка

$$\mathbf{H}^{(k)}(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_k(\mathbf{w}) = \frac{1}{k} \sum_{i=1}^k \nabla_{\mathbf{w}}^2 \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i) = \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w})$$
$$\mathcal{L}_k(\mathbf{w}) \approx \mathcal{L}_k(\mathbf{w}^*) + \frac{1}{2}(\mathbf{w} - \mathbf{w}^*)^\top \mathbf{H}^{(k)}(\mathbf{w}^*)(\mathbf{w} - \mathbf{w}^*)$$

Абсолютное изменение функции потерь

$$|\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})| \leq \frac{1}{k+1} \left| \ell(f_{\mathbf{w}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \frac{1}{k} \sum_{i=1}^k \ell(f_{\mathbf{w}^*}(\mathbf{x}_i), \mathbf{y}_i) \right|$$
$$+ \frac{1}{k+1} \|\mathbf{w} - \mathbf{w}^*\|_2^2 \left\| \mathbf{H}_{k+1}(\mathbf{w}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}^*) \right\|_2$$

Декомпозиция Гессиана и его аппроксимация

Декомпозиция Гессиана

$$\mathbf{H}_i(\mathbf{w}) = \underbrace{\nabla_{\mathbf{w}\mathbf{z}_i} \frac{\partial^2 \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial \mathbf{z}_i^2} \nabla_{\mathbf{w}\mathbf{z}_i}^\top}_{\text{G-term}} + \underbrace{\sum_{k=1}^K \frac{\partial \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial z_{ik}} \nabla_{\mathbf{w}}^2 z_{ik}}_{\text{H-term}}$$

Аппроксимация Гессиана

В задаче K -классовой классификации спектр Гессиана состоит из двух частей³: “bulk” (большое количество около нуля) и “outliers” (ровно K ненулевых). Поэтому часто для изучения нормы Гессиана пренебрегают H -членом, то есть

$$\mathbf{H}_i(\mathbf{w}) \approx \nabla_{\mathbf{w}\mathbf{z}_i} \frac{\partial^2 \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial \mathbf{z}_i^2} \nabla_{\mathbf{w}\mathbf{z}_i}^\top.$$

³Sagun, L. et al. (2017). Empirical analysis of the hessian of over-parametrized neural networks.
Papayan, V. (2018). The full spectrum of deepnet Hessians at scale: Dynamics with SGD training and sample size.

Частные случаи: MLP, CNN

Теорема

В полносвязной нейронной сети с числом слоев L , размером скрытого слоя h для всякого объекта i верно

$$\|\mathbf{H}_i(\mathbf{w})\|_2 \propto L(hM)^{2L}, \quad |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})| \propto \frac{L(hM)^{2L}}{k},$$

где M — константа, ограничивающая норму весов модели.





Теорема

В сверточной нейронной сети с числом слоев L , числом каналов C , размером ядра k для всякого объекта i верно

$$\|\mathbf{H}_i(\mathbf{w})\|_2 \propto L(\textcolor{red}{C}kM)^{2L}, \quad |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})| \propto \frac{L(\textcolor{red}{C}kM)^{2L}}{k},$$

где M — константа, ограничивающая норму весов модели.

Предварительные эксперименты



Обобщение на локальную окрестность


Ограничение предыдущих подходов

Оценка изменения поверхности функции потерь производится **в одной точке** (хотя размерность пространства параметров $N \gg 1$), не учитывается локальное поведение вблизи точек минимума.

Средневзвешенное изменение

$$\begin{aligned}\Delta_{k+1} &= \int (\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 p(\mathbf{w}) d\mathbf{w} = \\ &= \mathbb{E}_{p(\mathbf{w})} \left[(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],\end{aligned}$$

где $p(\mathbf{w})$ задает предпочтение по выбору точек в пространстве параметров (в общем случае может быть и не вероятностным распределением).



Теоретические результаты

Скорость сходимости (по размеру выборки k)

При выборе нормального распределения $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{w}^*, \sigma^2 \mathbf{I})$ можно доказать, что

$$\Delta_{k+1} \leq \frac{\sigma^4 N(N+2)M_{\mathbf{H}}^2}{2(k+1)^2},$$

где мы обозначили оценку на норму Гессиана как $M_{\mathbf{H}}$. Таким образом,

$$\Delta_k = \mathcal{O}\left(\frac{1}{k^2}\right)$$

Частные случаи (напоминание)

- ▶ Полносвязная нейронная сеть MLP: $M_{\mathbf{H}} = L(hM)^{2L}$
- ▶ Сверточная нейронная сеть CNN: $M_{\mathbf{H}} = L(\textcolor{red}{C}kM)^{2L}$

Вычислительный эксперимент

Исследовательские вопросы

- 1) Как меняется поверхность функции потерь в зависимости от архитектуры: Dropout, BatchNorm, количество слоев?
- 2) Как предложенная метрика Δ_k сходится на практике?
- 3) Может ли Δ_k быть геометрической интерпретацией достаточного размера выборки аналогично известным законам масштабирования?


Постановка эксперимента

- ▶ **Задача:** классификация изображений из датасета CIFAR-10;
- ▶ **Архитектура:** полносвязная и сверточная нейронные сети;
- ▶ **Визуализация:** выбираем случайное 2D подпространство, сэмплируя два направления $\mathbf{u}$, $\mathbf{v}$ и переходя к виду


$$f(\alpha, \beta) = \mathcal{L}(\mathbf{w}^* + \alpha \mathbf{u} + \beta \mathbf{v}).$$

Эксперимент 1: влияние Dropout и BatchNorm на поверхность


Dropout + BatchNorm



BatchNorm




Без обоих




Используются сверточные нейронные сети с 4 слоями. Видно, что BatchNorm сужает локальную окрестность минимума, а Dropout расширяет. Отсутствие обоих приводит к нестабильному минимуму.

Эксперимент 2: влияние количества слоев на поверхность


2 слоя



4 слоя




6 слоев




Используются сверточные нейронные сети. Видно, что увеличение числа слоев приводит к значительному расширению локального минимума и более сложной геометрии.


Эксперимент 3: сходимость поверхности при увеличении k



(a) $(\mathcal{L}_1 - \mathcal{L}_2)^2 p(\mathbf{w})$



(b) $(\mathcal{L}_{50} - \mathcal{L}_{49})^2 p(\mathbf{w})$



(c) $(\mathcal{L}_{100} - \mathcal{L}_{101})^2 p(\mathbf{w})$

Рассматривается нормальное распределение с центром в точке минимума. Изменяется количество используемых данных для подсчета: слева 2 объекта, по центру 50 объектов, справа 100 объектов. Видно, что при увеличении k начинает уменьшаться эффективная локальность окрестность.

Заключение

- 1) Получена оценка для Δ_k при выборе $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{w}^*, \sigma^2\mathbf{I})$ в окрестности минимума
- 2) Исследовано влияние архитектуры модели на ландшафт функции потерь.
- 3) Дальнейшее исследование лежит в направлении развития конкретного метода прогнозирования достаточного размера выборки на основе введенной метрики Δ_k .

Список работ автора по теме исследования

- 1) **Kiselev N. S.**, Grabovoy A. V. Sample Size Determination: Likelihood Bootstrapping // *Computational Mathematics and Mathematical Physics*, 2025.
- 2) **Kiselev N.**, Grabovoy A. Sample Size Determination: Posterior Distributions Proximity // *Computational Management Science*, 2025.
- 3) **Kiselev N. S.**, Grabovoy A. V. Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // *Doklady Mathematics*, 2024.
- 4) Meshkov V., **Kiselev N.**, Grabovoy A. ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks // *2024 Ivannikov ISPRAS Open Conference (ISPRAS): Proceedings*, 2024.

Спасибо за внимание ;)