

Определение достаточного размера выборки по апостериорному распределению параметров модели

Киселев Никита Сергеевич

Научный руководитель:
к.ф.-м.н. А. В. Грабовой

Московский физико-технический институт
(национальный исследовательский университет)
Физтех-школа прикладной математики и информатики
Кафедра интеллектуальных систем

Москва — 2024

Определение достаточного размера выборки по апостериорному распределению параметров модели

Исследуется задача определения достаточного размера выборки.

Проблема

Определение достаточного размера выборки без постановки статистической гипотезы о распределении параметров модели.

Цель

Предложить критерий определения достаточного размера выборки. Построить метод, реализующий этот критерий на практике.

Решение

Предлагаются подходы к определению достаточного размера выборки по близости апостериорных распределений параметров модели на схожих подвыборках.

Постановка задачи определения достаточного размера выборки

Выборка

$$\mathfrak{D}_m = \{(\mathbf{x}_i, y_i)\}, i \in \mathcal{I} = \{1, \dots, m\},$$

где $\mathbf{x} \in \mathbb{X} \subseteq \mathbb{R}^n$ есть вектор признакового описания объекта, а $y \in \mathbb{Y}$ есть значение целевой переменной.

Вероятностная модель

$$p(y, \mathbf{w}|\mathbf{x}) = p(y|\mathbf{x}, \mathbf{w})p(\mathbf{w}) : \mathbb{Y} \times \mathbb{W} \times \mathbb{X} \rightarrow \mathbb{R}^+,$$

где $p(y|\mathbf{x}, \mathbf{w})$ задает правдоподобие объекта, а $p(\mathbf{w})$ задает априорное распределение параметров.

Определение

Размер выборки m^* называется **достаточным** согласно критерию T , если T выполняется для всех $k \geq m^*$.

Требуется

Предложить критерий T определения достаточного размера выборки m^* . Построить метод, реализующий критерий T на практике.

Апостериорные распределения параметров на схожих подвыборках

Рассмотрим две подвыборки $\mathfrak{D}^1 \subseteq \mathfrak{D}_m$ и $\mathfrak{D}^2 \subseteq \mathfrak{D}_m$. Пусть $\mathcal{I}_1 \subseteq \mathcal{I} = \{1, \dots, m\}$ и $\mathcal{I}_2 \subseteq \mathcal{I} = \{1, \dots, m\}$ — соответствующие им подмножества индексов.

Определение¹

Подвыборки $\mathfrak{D}^1$ и $\mathfrak{D}^2$ называются **схожими**, если $\mathcal{I}_2$ может быть получено из $\mathcal{I}_1$ удалением, заменой или добавлением одного элемента, то есть

$$|\mathcal{I}_1 \triangle \mathcal{I}_2| = |(\mathcal{I}_1 \setminus \mathcal{I}_2) \cup (\mathcal{I}_2 \setminus \mathcal{I}_1)| = 1.$$

Рассмотрим две схожие подвыборки $\mathfrak{D}_k = (\mathbf{X}_k, \mathbf{y}_k)$ и $\mathfrak{D}_{k+1} = (\mathbf{X}_{k+1}, \mathbf{y}_{k+1})$ размеров k и $k + 1$ соответственно. Найдём апостериорное распределение параметров модели по этим подвыборкам:

$$p_j(\mathbf{w}) = p(\mathbf{w} | \mathfrak{D}_j) = \frac{p(\mathfrak{D}_j | \mathbf{w}) p(\mathbf{w})}{p(\mathfrak{D}_j)} \propto p(\mathfrak{D}_j | \mathbf{w}) p(\mathbf{w}), \quad j = k, k + 1.$$

¹Motrenko A., Strijov V., Weber G-W. Sample size determination for logistic regression. Journal of Computational and Applied Mathematics, 2014.

Предлагаемые определения достаточного размера выборки

Определение (KL-достаточный размер выборки)

Зафиксируем некоторое положительное число $\varepsilon > 0$. Размер выборки m^* называется **KL-достаточным**, если для всех $k \geq m^*$

$$KL(k) = D_{KL}(p_k \| p_{k+1}) = \int p_k(\mathbf{w}) \log \frac{p_k(\mathbf{w})}{p_{k+1}(\mathbf{w})} d\mathbf{w} \leq \varepsilon.$$

Определение (S-достаточный размер выборки)

Зафиксируем некоторое положительное число $\varepsilon > 0$. Размер выборки m^* называется **S-достаточным**, если для всех $k \geq m^*$

$$S(k) = \text{s-score}(p_k, p_{k+1}) \geq 1 - \varepsilon.$$

$$\text{s-score}(g_1, g_2) = \frac{\int_{\mathbf{w}} g_1(\mathbf{w}) g_2(\mathbf{w}) d\mathbf{w}}{\max_{\mathbf{b}} \int_{\mathbf{w}} g_1(\mathbf{w} - \mathbf{b}) g_2(\mathbf{w}) d\mathbf{w}}$$

Сходимость рассматриваемых функций близости распределений

Предположим, что апостериорное распределение является нормальным, то есть $p_k(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}_k, \Sigma_k)$.

Теорема 1

Пусть $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$ при $k \rightarrow \infty$. Тогда в модели с нормальным апостериорным распределением параметров определение KL-достаточного размера выборки является корректным. А именно, для любого $\varepsilon > 0$ найдется такой m^* , что для всех $k \geq m^*$ выполнено $KL(k) \leq \varepsilon$.

Теорема 2

Пусть $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ при $k \rightarrow \infty$. Тогда в модели с нормальным апостериорным распределением параметров определение S-достаточного размера выборки является корректным. А именно, для любого $\varepsilon > 0$ найдется такой m^* , что для всех $k \geq m^*$ выполнено $S(k) \geq 1 - \varepsilon$.

Модель линейной регрессии с нормальным априорным распределением

Вероятностная модель линейной регрессии

$$p(\mathbf{y}, \mathbf{w}|\mathbf{X}) = p(\mathbf{y}|\mathbf{X}, \mathbf{w})p(\mathbf{w}) = \mathcal{N}(\mathbf{y}|\mathbf{X}\mathbf{w}, \sigma^2\mathbf{I}) \mathcal{N}(\mathbf{w}|\mathbf{0}, \alpha^{-1}\mathbf{I})$$

Апостериорное распределение

$$p(\mathbf{w}|\mathbf{X}, \mathbf{y}) = \mathcal{N}(\mathbf{w}|\mathbf{m}, \Sigma),$$

$$\Sigma = \left(\alpha\mathbf{I} + \frac{1}{\sigma^2}\mathbf{X}^\top\mathbf{X} \right)^{-1}, \quad \mathbf{m} = (\mathbf{X}^\top\mathbf{X} + \alpha\sigma^2\mathbf{I})^{-1} \mathbf{X}^\top\mathbf{y}.$$


Теорема 3

Пусть множества значений признаков и целевой переменной ограничены, то есть $\exists M \in \mathbb{R} : \|\mathbf{x}\|_2 \leq M$ и $|y| \leq M$. Если $\lambda_{\min}(\mathbf{X}_k^\top\mathbf{X}_k) = \omega(\sqrt{k})$ при $k \rightarrow \infty$, то в модели линейной регрессии с нормальным априорным распределением параметров $\|\mathbf{m}_{k+1} - \mathbf{m}_k\|_2 \rightarrow 0$ и $\|\Sigma_{k+1} - \Sigma_k\|_F \rightarrow 0$ при $k \rightarrow \infty$.

Сходимость апостериорных распределений в одномерном случае

- ▶ Синтетическая выборка линейной регрессии;
- ▶ Число объектов 100, число признаков 1;
- ▶ Априорное распределение параметров $\mathcal{N}(\mathbf{w}|\mathbf{0}, \mathbf{I})$.

Ниже — плотности апостериорных распределений для подвыборок размера k и $k + 1$.




При увеличении доступного размера выборки апостериорные распределения параметров модели на схожих подвыборках становятся ближе.

Сходимость апостериорных распределений в двумерном случае

- ▶ Синтетическая выборка линейной регрессии;
- ▶ Число объектов 100, число признаков 2;
- ▶ Априорное распределение параметров $\mathcal{N}(\mathbf{w}|\mathbf{0}, \mathbf{I})$.



Ниже — линии уровня плотностей распределения для подвыборок размера k и $k + 1$.



При увеличении доступного размера выборки апостериорные распределения параметров модели на схожих подвыборках становятся ближе.

Асимптотическое поведение $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)$

- ▶ Две выборки:
 1. Синтетическая выборка линейной регрессии — 500 объектов, 10 признаков;
 2. Выборка Liver Disorders из UCI² — 345 объектов, 5 признаков;
- ▶ Один объект последовательно удаляется из выборки, пока число объектов не станет равно числу признаков;
- ▶ Такой процесс повторяется $B = 100$ раз.




Видно, что $\lambda_{\min}(\mathbf{X}_k^\top \mathbf{X}_k)$ стремится к бесконечности асимптотически быстрее, чем $\sqrt{k}$.

²Markelle Kelly, Rachel Longjohn, Kolby Nottingham, The UCI Machine Learning Repository.

Сходимость рассматриваемых функций близости распределений


- ▶ Выборка Liver Disorders — 345 объектов, 5 признаков;
- ▶ Один объект последовательно удаляется из выборки, пока число объектов не станет равно числу признаков;
- ▶ Такой процесс повторяется $B = 100$ раз.



Значения функции $KL(k)$ стремятся к нулю при увеличении размера выборки, а значения $S(k)$ стремятся к единице. Эти эмпирические результаты подтверждают теоретические, представленные ранее.

Варьирование гиперпараметра ε для достаточного размера выборки

В определениях KL-достаточности и S-достаточности участвует гиперпараметр ε , который отвечает за порог для достаточного размера выборки m^* . Следующий рисунок демонстрирует, какой размер выборки следует выбрать, чтобы обеспечить определенный уровень уверенности.



Для $\varepsilon = 10$ достаточно взять число объектов, равное числу признаков. Однако для $\varepsilon = 10^{-2}$ требуется взять всю выборку.

Заключение

- ▶ Предложены подходы к определению достаточного размера выборки на основе близости апостериорных распределений на схожих подвыборках.
- ▶ Доказана корректность подходов в вероятностной модели с нормальным апостериорным распределением параметров.
- ▶ Доказана теорема о моментах предельного апостериорного распределения параметров в модели линейной регрессии.
- ▶ Проведен вычислительный эксперимент для анализа предложенных подходов.