

Достаточный размер обучающей выборки и его связь со сходимостью поверхности функции потерь

Киселев Н.С., Мешков В.С., Грабовой А.В.

Московский физико-технический институт
(национальный исследовательский университет)

ММРО, 25 сентября 2025

Достаточный размер обучающей выборки и его связь со сходимостью поверхности функции потерь

Проблема

Количество данных для обучения модели неразрывно связано с ее сложностью. При этом всегда есть желание сократить число объектов для обучения.

Цель

Разработать методы определения необходимого числа данных для обучения модели с заранее определенным качеством.
Связать количество данных со сложностью модели.

Источники для решения

1. Статистические критерии. ✗
2. Распределение параметров модели после обучения. ✓
3. Изменение функции потерь с ростом числа объектов. ✓

Классическая постановка задачи определения достаточного размера выборки

Выборка

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}, \quad i = 1, \dots, m$$

- ▶ $\mathbf{x} \in \mathbb{X} \subseteq \mathbb{R}^n$ — вектор признакового описания объекта;
- ▶ $y \in \mathbb{Y}$ — значение целевой переменной.

Вероятностная модель

$$p(y, \mathbf{w}|\mathbf{x}) = p(y|\mathbf{x}, \mathbf{w})p(\mathbf{w}) : \mathbb{Y} \times \mathbb{W} \times \mathbb{X} \rightarrow \mathbb{R}^+$$

- ▶ $p(y|\mathbf{x}, \mathbf{w})$ — правдоподобие;
- ▶ $p(\mathbf{w})$ — априорное распределение.

Классическая постановка задачи определения достаточного размера выборки

Определение

Размер выборки m^* называется **достаточным** согласно критерию T , если T выполняется для всех $k \geq m^*$.

Требуется

- ▶ Предложить критерий T определения достаточного размера выборки m^* ;
- ▶ Построить метод, реализующий критерий T на практике.

Классические подходы и первые обобщения¹


Методы определения достаточного размера выборки исходно формулировались для статистических критериев. Исходя из этого их чаще всего классифицируют следующим образом.

1. **Статистические.** Ставится нулевая гипотеза, и мы хотим понять минимальное количество данных, необходимое для достижения **заданной мощности стат. критерия**.
2. **Эвристические.** Используют широко известные методы по типу бутстрапирования, кросс-валидации, выбора признаков.
3. **Байесовские.** Параметры модели рассматриваются как случайные величины. Критерии на основе ожидаемых по подвыборкам величин.

¹Grabovoy, A.V., Gadaev, T.T., Motrenko, A.P. et al. Numerical Methods of Sufficient Sample Size Estimation for Generalised Linear Models. Lobachevskii J Math 43, 2453–2462 (2022).

Близость апостериорных распределений на схожих подвыборках²

1. Рассматриваем две подвыборки, отличающиеся на один объект: $\mathfrak{D}_k$ и $\mathfrak{D}_{k+1}$
2. Подсчитываем апостериорные распределения параметров: $p_k(\mathbf{w}) = p(\mathbf{w}|\mathfrak{D}_k)$ и $p_{k+1}(\mathbf{w}) = p(\mathbf{w}|\mathfrak{D}_{k+1})$
3. Сравниваем их по дивергенции Кульбака–Лейблера:
 $D_{\text{KL}}(p_k \| p_{k+1})$



²Kiselev, N., & Grabovoy, A. (2025). Sample size determination: posterior distributions proximity. Computational Management Science, 22(1), 1.

Близость полных байесовских прогнозов для линейной регрессии

Разделение на обучающую и тестовую выборки

$$\mathfrak{D}_m = \mathfrak{D}_{m_1}^{\text{train}} \sqcup \mathfrak{D}_{m_2}^{\text{test}}, \quad (\mathbf{X}_k, \mathbf{y}_k) \subset \mathfrak{D}_{m_1}^{\text{train}}$$

Теорема


Пусть множества значений признаков и целевой переменной ограничены, то есть $\exists M \in \mathbb{R} : \|\mathbf{x}\|_2 \leq M$ и $|y| \leq M$. Если $\lambda_{\min}(\mathbf{X}_k^T \mathbf{X}_k) = \omega(\sqrt{k})$ при $k \rightarrow \infty$, то **в модели линейной регрессии с нормальным априорным распределением параметров**

$$\|\mathbb{E}[\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_{k+1}, \mathbf{y}_{k+1}] - \mathbb{E}[\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k]\|_2 \rightarrow 0,$$

$$\|\mathbb{D}[\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_{k+1}, \mathbf{y}_{k+1}] - \mathbb{D}[\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k]\|_F \rightarrow 0,$$

$$D_{\text{KL}}(p(\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_k, \mathbf{y}_k) \| p(\mathbf{y}_{\text{test}} | \mathbf{X}_{\text{test}}, \mathbf{X}_{k+1}, \mathbf{y}_{k+1})) \rightarrow 0.$$

Сходимость поверхности функции потерь³⁴



³Kiselev, N., & Grabovoy, A. (2024). Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes. Doklady Mathematics.

⁴Meshkov, V., Kiselev, N., and Grabovoy, A. (2024). ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks. Ivannikov Ispras Open Conference (ISPRAS).

Обозначения

Выборка

$$\mathfrak{D} = \{(\mathbf{x}_i, \mathbf{y}_i)\}, \quad i = 1, \dots, m, \quad \mathbf{x} \in \mathcal{X}, \mathbf{y} \in \mathcal{Y}$$

Модель

Условное распределение $p(\mathbf{y}|\mathbf{x})$ аппроксимируется нейросетью $f_{\mathbf{w}} : \mathcal{X} \rightarrow \mathcal{Y}$ с параметрами $\mathbf{w} \in \mathbb{R}^N$.

Функция потерь

$$\mathcal{L}_m(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i) \approx \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim p(\mathbf{x}, \mathbf{y})} [\ell(f_{\mathbf{w}}(\mathbf{x}), \mathbf{y})]$$

Изменение значения при добавлении одного объекта

$$\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}) = \frac{1}{k+1} (\ell(f_{\mathbf{w}}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \mathcal{L}_k(\mathbf{w}))$$

Аппроксимация второго порядка

Предположение 1

Пусть $\mathbf{w}^*$ является точкой минимума обеих функций $\mathcal{L}_k(\mathbf{w})$ и $\mathcal{L}_{k+1}(\mathbf{w})$, то есть $\nabla \mathcal{L}_k(\mathbf{w}^*) = \nabla \mathcal{L}_{k+1}(\mathbf{w}^*) = \mathbf{0}$.

Аппроксимация второго порядка

$$\mathbf{H}^{(k)}(\mathbf{w}) = \nabla_{\mathbf{w}}^2 \mathcal{L}_k(\mathbf{w}) = \frac{1}{k} \sum_{i=1}^k \nabla_{\mathbf{w}}^2 \ell(f_{\mathbf{w}}(\mathbf{x}_i), \mathbf{y}_i) = \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w})$$

$$\mathcal{L}_k(\mathbf{w}) \approx \mathcal{L}_k(\mathbf{w}^*) + \frac{1}{2}(\mathbf{w} - \mathbf{w}^*)^\top \mathbf{H}^{(k)}(\mathbf{w}^*)(\mathbf{w} - \mathbf{w}^*)$$

Абсолютное изменение функции потерь

$$\begin{aligned} |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})| &\leq \frac{1}{k+1} \left| \ell(f_{\mathbf{w}^*}(\mathbf{x}_{k+1}), \mathbf{y}_{k+1}) - \frac{1}{k} \sum_{i=1}^k \ell(f_{\mathbf{w}^*}(\mathbf{x}_i), \mathbf{y}_i) \right| \\ &\quad + \frac{1}{k+1} \|\mathbf{w} - \mathbf{w}^*\|_2^2 \left\| \mathbf{H}_{k+1}(\mathbf{w}^*) - \frac{1}{k} \sum_{i=1}^k \mathbf{H}_i(\mathbf{w}^*) \right\|_2 \end{aligned}$$

Декомпозиция Гессиана и его аппроксимация

Декомпозиция Гессиана

$$\mathbf{H}_i(\mathbf{w}) = \underbrace{\nabla_{\mathbf{w}} \mathbf{z}_i \frac{\partial^2 \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial \mathbf{z}_i^2} \nabla_{\mathbf{w}} \mathbf{z}_i^\top}_{\text{G-term}} + \underbrace{\sum_{k=1}^K \frac{\partial \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial z_{ik}} \nabla_{\mathbf{w}}^2 z_{ik}}_{\text{H-term}}$$

Аппроксимация Гессиана

В задаче K -классовой классификации спектр Гессиана состоит из двух частей⁵: “bulk” (большое количество около нуля) и “outliers” (ровно K ненулевых). Поэтому часто для изучения нормы Гессиана пренебрегают H -членом, то есть

$$\mathbf{H}_i(\mathbf{w}) \approx \nabla_{\mathbf{w}} \mathbf{z}_i \frac{\partial^2 \ell(\mathbf{z}_i, \mathbf{y}_i)}{\partial \mathbf{z}_i^2} \nabla_{\mathbf{w}} \mathbf{z}_i^\top.$$

⁵Sagun, L. et al. (2017). Empirical analysis of the hessian of over-parametrized neural networks.

Papayan, V. (2018). The full spectrum of deepnet Hessians at scale: Dynamics with SGD training and sample size.

Частные случаи: MLP, CNN

Теорема

В полносвязной нейронной сети с числом слоев L , размером скрытого слоя h для всякого объекта i верно

$$\|\mathbf{H}_i(\mathbf{w})\|_2 \propto L(hM)^{2L}, \quad |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})| \propto \frac{L(hM)^{2L}}{k},$$

где M — константа, ограничивающая норму весов модели.





Теорема

В сверточной нейронной сети с числом слоев L , числом каналов C , размером ядра k для всякого объекта i верно

$$\|\mathbf{H}_i(\mathbf{w})\|_2 \propto L(\textcolor{red}{C}kM)^{2L}, \quad |\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w})| \propto \frac{L(\textcolor{red}{C}kM)^{2L}}{k},$$

где M — константа, ограничивающая норму весов модели.

Предварительные эксперименты



Обобщение на локальную окрестность⁶

Ограничение предыдущих подходов

Оценка изменения поверхности функции потерь производится в **одной точке** (хотя размерность пространства параметров $N \gg 1$), не учитывается локальное поведение вблизи точек минимума.

Средневзвешенное изменение

$$\begin{aligned}\Delta_{k+1} &= \int (\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 p(\mathbf{w}) d\mathbf{w} = \\ &= \mathbb{E}_{p(\mathbf{w})} \left[(\mathcal{L}_{k+1}(\mathbf{w}) - \mathcal{L}_k(\mathbf{w}))^2 \right],\end{aligned}$$

где $p(\mathbf{w})$ задает предпочтение по выбору точек в пространстве параметров (в общем случае может быть и не вероятностным распределением).

⁶Kiselev, N., Meshkov, and V., Grabovoy, A. Robust Convergence of Loss Landscapes through Distributional Averaging. Submitted to Doklady Mathematics.

Переход в линейное подпространство

При выборе нормального распределения $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}, \sigma^2\mathbf{I})$ можно доказать, что

$$\Delta_{k+1} \leq \frac{\sigma^4 N(N+2)M_{\mathbf{H}}^2}{2(k+1)^2},$$

где мы обозначили оценку на норму Гессиана как $M_{\mathbf{H}}$. Сложность заключается в том, что данное выражение Δ_{k+1} невозможно применить на практике, не зная $M_{\mathbf{H}}$.

Метод проекции на линейное подпространство

Предлагается рассмотреть нормальное распределение не во всем пространстве параметров, а в **линейном подпространстве**, натянутом на D векторов, соответствующих D наибольшим собственным значениям Гессиана $\lambda_k^{(1)}, \dots, \lambda_k^{(D)}$.

Подпространство собственных векторов Гессиана

Изменение: $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{m}, \sigma^2 \mathbf{I}_N) \rightarrow p(\boldsymbol{\theta}) = \mathcal{N}(\boldsymbol{\theta}|\mathbf{0}, \sigma^2 \mathbf{I}_D)$.

Теоретическая оценка

$$\Delta_{k+1} \leq \frac{\sigma^4}{4} \left(2 \sum_{d=1}^D \left(\lambda_{k+1}^{(d)} - \lambda_k^{(d)} \right)^2 + \left(\sum_{d=1}^D \left(\lambda_{k+1}^{(d)} - \lambda_k^{(d)} \right) \right)^2 \right)$$



Практическое применение (Монте-Карло)

$$\Delta_{k+1} \approx \frac{1}{B} \sum_{t=1}^B (\mathcal{L}_{k+1}(\boldsymbol{\theta}^{(t)}) - \mathcal{L}_k(\boldsymbol{\theta}^{(t)}))^2, \quad \boldsymbol{\theta}^{(t)} \sim p(\boldsymbol{\theta})$$



Вычислительный эксперимент 1

Сравниваются ландшафты в окрестности минимума (слева — функция ошибки, справа — ее изменение при добавлении одного батча).

Подпространство **случайных векторов**




Подпространство **наибольших собственных векторов Гессiana**



Вычислительный эксперимент 2

Сравниваются теоретическая и эмпирическая оценки Δ_k .



Проведенные эксперименты демонстрируют справедливость теоретических результатов: подпространство собственных векторов Гессiana более информативное, а теоретическая оценка Δ_k действительно может быть применена в качестве критерия достаточного размера выборки.

Заключение

1. Получено выражение Δ_k при выборе $p(\boldsymbol{\theta}) = \mathcal{N}(\boldsymbol{\theta}|\mathbf{0}, \sigma^2 \mathbf{I}_D)$ в линейном подпространстве, натянутом на D с.в. Гессиана, соответствующих наибольшему с.з.
2. Исследовано влияние перехода к такому подпространству на ландшафт функции ошибки в окрестности точки минимума.
3. Дальнейшее исследование лежит в направлении развития конкретного метода прогнозирования достаточного размера выборки на основе введенной метрики Δ_k .

Список работ автора по теме исследования

1. **N. Kiselev**, A. Grabovoy (2025). Sample size determination: likelihood bootstrapping. Computational Mathematics and Mathematical Physics, 65(2), 416-423.
2. **N. Kiselev**, A. Grabovoy (2025). Sample size determination: posterior distributions proximity. Computational Management Science, 22(1), 1.
3. **N. Kiselev**, A. Grabovoy (2024). Unraveling the hessian: A key to smooth convergence in loss function landscapes. Doklady Mathematics, 110(1), 49–61.
4. V. Meshkov, **N. Kiselev**, A. Grabovoy (2024). ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks. In 2024 Ivannikov Ispras Open Conference (ISPRAS) (pp. 1-10). IEEE.