

**САЛЮТ,
ГИГА**

Kandinsky: запускаем и дообучаем модели генерации изображений и видео

Никита Киселев

ML Research Engineer @ Kandinsky Post-Train

**KAND
INSKY**

Какую задачу решаем?



Хотим добавить в знания модели новую сущность (персонализация)

- 1 Исходно модель не умеет генерировать некую сущность
- 2 Невозможно подобрать промпт или он крайней нестабилен
- 3 Есть возможность собрать небольшой датасет и дообучить


До обучения




После обучения




Что нужно для персонализации?



Написание кода
дообучения



Сбор данных
и подготовка
в нужном формате



Согласованность
формата промпта
на инференсе





Диффузионные модели



Стохастические дифференциальные уравнения

Прямое СДУ (данные → шум)



Обратное СДУ (шум → данные)


нейронная сеть $\epsilon_{\theta}(\mathbf{x}_t, t)$

Современные архитектуры



Diffusion Transformer (Kandinsky 5.0)

1. Диффузионный процесс происходит в латентном пространстве предобученного VAE
2. Латент — это 4D-тензор $[T, H, W, C]$, который разбивается на патчи — токены для трансформера
3. DiT состоит из последовательности блоков с Cross-Attention на текстовую инструкцию (промпт)



Современные архитектуры




Cross-DiT (Kandinsky 5.0)

1. Self-Attention
2. Cross-Attention (с промптом)
3. Feed Forward

Будем учить слои-проекции:

W_Q, W_K, W_V




Live Coding: дообучаем Kandinsky



Добавим в знания модели новую сущность — лабubu!

Метод дообучения — LoRA



Нам понадобятся



Милый пушистый персонаж лабubu коричневого цвета сидит на песчаном пляже под пальмами. Рядом лежит маленький радиоприемник, на фоне — голубое море и ясное небо с облаками. Атмосфера теплая и летняя.

Картинки

+

Текстовые
описания

Live Coding: формат данных для дообучения и генерации



Обучение



VLM

Текстовое
описание

Задача: получить подробное текстовое описание

Алгоритм:

1. Пропускаем изображение через VLM
2. Нормализуем кэпшен:
 - Добавляем триггер слово
 - *Добавляем контекстную фразу

Инференс: текст → изображение/видео

Промпт
+
триггер

Kandinsky



Задача: повторить формат данных из обучения

Алгоритм:

1. Составляем подробный промпт
2. Добавляем триггер слово
3. *Добавляем контекстную фразу